

Rapport technique : Génération de légendes d'images avec ViT + GPT-2

1. Introduction

Ce rapport présente une méthode de génération automatique de légendes pour des images en utilisant une architecture à deux composantes :

- Vision Transformer (ViT) pour l'encodage d'images
- GPT-2 pour la génération de texte

La méthode implémentée correspond à l'architecture dite CLIP-GPT2 (ou ViT2GPT) et suit les standards des bibliothèques de HuggingFace Transformers.

2. Architecture de la solution

a. ViT : Vision Transformer (Encodeur image)

L'image est d'abord redimensionnée (640x640) puis divisée en petits patches. Ces patches sont transformés en vecteurs grâce à :

- Une projection linéaire des patches
- Un ajout d'encodages positionnels
- Un passage à travers un Transformer Encoder

Référence schéma : Architecture of ViT.png

Vision Transformer (ViT)




Figure: Architecture du Vision Transformer (ViT)

b. GPT-2 : Générateur de texte (Décodeur)

Après encodage, les vecteurs sont passés au décodeur GPT-2, qui utilise :

- Attention masquée multi-tête
- Normalisation par couche
- Couches feed-forward

Cela permet la prédiction séquentielle des mots d'une légende.

Référence schéma : decoder GPT-2.png




Figure: Structure interne du décodeur GPT-2

c. Système complet : ViT → GPT-2

Le pipeline complet se résume ainsi :

1. Image → Feature Extractor ViT
2. ViT embeddings → VisionEncoderDecoderModel
3. VisionEncoderDecoderModel → GPT-2 → texte

Référence schéma : système generale.png




Figure: Architecture du Vision Transformer (ViT)

3. Implémentation Python

L'implémentation suit exactement l'architecture ci-dessus. Les grandes étapes sont :

a. Prétraitement

- Chargement de Flickr30k
- Redimensionnement images (640x640)
- Transformation en tenseurs et tokenisation des légendes

b. Entraînement

- Modèle : VisionEncoderDecoderModel(ViT, GPT2)
- Métrique : ROUGE-2

- Batch training, early stopping, beam search, etc.

c. Évaluation et génération

- Affichage des courbes Loss, ROUGE-2
- Génération de légendes pour des images test

4. Conclusion

Ce projet implémente fidèlement un modèle d'image captioning fondé sur ViT + GPT-2. Les schémas fournis permettent de visualiser clairement chaque étape du processus. Ce pipeline peut être adapté à d'autres jeux de données et d'autres décodeurs pour divers cas d'usage.